Detección de fauna en cámaras trampa con YOLOv8: diversidad de cámaras y generalización a escenas nuevas

Integrante 1 Integrante 2 Integrante 3 Integrante 4 Integrante 5
Maestría en Inteligencia Artificial, Facultad de Ingeniería Industrial y de Sistemas
Universidad Nacional de Ingeniería, Lima, Perú

Resumen

Los detectores de fauna entrenados en un conjunto de cámaras trampa pierden desempeño al instalarse en otras. Se ajustan dos detectores YOLOv8-s preentrenados en COCO: A, con la partición oficial de Caltech Camera Traps (CCT-20) de Beery et al. (2018), y B, que añade las cámaras externas del conjunto completo con cajas de las 15 clases y comparte con A la validación, el umbral de operación y los conjuntos de prueba. En las 9 cámaras nuevas de la partición oficial, el mAP@0.5 pasa de 40.6 % a 48.5 %, con una mejora pareada por *bootstrap* de cámaras de 7.8 puntos (IC 95 % [5.2, 12.2]); en 30 cámaras nuevas adicionales, de 21.0 % a 51.7 %. La brecha entre cámaras vistas y nuevas persiste en ambos modelos (A: 26.0 puntos; B: 25.0). La caída del AUROC entre vacías y fauna (de 0.963 a 0.712 en A) y los mapas Grad-CAM indican dependencia del contexto, que B atenúa. El tamaño del objeto domina la dificultad; un módulo de monitoreo basado en reglas reproduce el número de eventos de una cámara nueva, pero no su composición de especies, y en ENA24-detection el AP agnóstico (83.0 %) supera ampliamente al mAP por clase (33.2 %).

1. Introducción

El monitoreo de biodiversidad con cámaras trampa se ha consolidado en áreas protegidas, incluidos los programas de conservación de la Amazonía y los Andes peruanos. Su cuello de botella es la revisión manual. En el conjunto completo de Caltech Camera Traps (CCT), más de la mitad de los fotogramas no contiene fauna, y fuera del subconjunto curado CCT-20 esa fracción llega al 69.9 %. El aprendizaje profundo ha automatizado la clasificación de especies en colecciones grandes (Norouzzadeh et al., 2018; Tabak et al., 2019), pero el desempeño medido en las cámaras de entrenamiento sobreestima el que se obtiene en cámaras nuevas. Beery et al. (2018) documentaron un incremento del error de clasificación superior al 100 % entre ubicaciones vistas (*cis*) y nuevas (*trans*), y la literatura lo atribuye al aprendizaje de atajos de contexto (Geirhos et al., 2020; Ribeiro et al., 2016).

Este trabajo responde la Pregunta 3 del examen con dos detectores que difieren en el número de cámaras de entrenamiento. Aporta una auditoría del conjunto completo, la cuantificación de la brecha cis/trans en dos conjuntos de cámaras nuevas con tres pruebas de dependencia del fondo, un análisis de robustez frente a oclusión y tamaño, un módulo de monitoreo evaluado en una cámara nunca vista, y una evaluación entre conjuntos de datos sobre ENA24-detection (Yousif et al., 2019).

2. Trabajos relacionados

Reconocimiento de fauna en cámaras trampa. Norouzzadeh et al. (2018) entrenaron redes convolucionales sobre Snapshot Serengeti para detectar presencia, identificar especies y contar individuos. Tabak et al. (2019) mostraron que un clasificador entrenado con datos de América del Norte pierde exactitud al aplicarse a otra región. Schneider et al. (2018) compararon Faster R-CNN y

YOLO como detectores de fauna, y Schneider et al. (2020) identificaron la diversidad de ubicaciones de entrenamiento como un factor crítico del desempeño en cámaras nuevas, hipótesis que el modelo B somete a prueba. MegaDetector (Beery et al., 2019) separa la detección agnóstica de la clasificación, una estrategia que Shepley et al. (2021) adoptaron para reducir la dependencia de la ubicación. Tuia et al. (2022) revisan estas líneas en el contexto de la conservación.

Generalización fuera de distribución. Beery et al. (2018) propusieron CCT-20 y su partición cis/trans; con Faster R-CNN obtuvieron $\sim$77 % de mAP@0.5 en cis y $\sim$71 % en trans a nivel de fotograma. WILDS incluye iWildCam como caso de cambio de dominio por ubicación (Koh et al., 2021). El aprendizaje de atajos (Geirhos et al., 2020) y la explicación de decisiones (Ribeiro et al., 2016; Selvaraju et al., 2017) dan el marco para preguntar qué rasgos usa el detector.

Detectores de una etapa. YOLO formuló la detección como regresión densa en una pasada (Redmon et al., 2016). YOLOv4 incorporó el mosaico y la red troncal CSP (Bochkovskiy et al., 2020; Wang et al., 2020). YOLOv8 (Jocher et al., 2023) combina bloques C2f, un cuello PAN-FPN (Lin et al., 2017; Liu et al., 2018), un cabezal desacoplado sin anclas, asignación alineada a la tarea (Feng et al., 2021) y la pérdida focal distribucional (Li et al., 2020). YOLOv9 (Wang et al., 2024) es su sucesor inmediato (Terven et al., 2023).

3. Metodología

3.1. Datos, auditoría y particiones

CCT contiene 244 496 registros de imagen de 140 cámaras del suroeste de Estados Unidos. CCT-20 es el subconjunto de 20 cámaras y 15 clases que Beery et al. (2018) usaron para medir generalización. La partición oficial `eccv_train`/`eccv_val` asigna sus 10 cámaras cis a entrenamiento y sus 10 cámaras trans a evaluación. Dentro de las cis, los días impares forman `cis_test` y de los pares se extrae un 5 % como `cis_val` sin compartir secuencias. Las trans se dividen en una cámara de validación y nueve de prueba.

La auditoría del conjunto completo frente a CCT-20 (tabla 8, apéndice) arrojó tres hallazgos que guían el diseño. Primero, CCT-20 está curado: solo un 6.9 % de sus imágenes son vacías, y la partición `train` no contiene ninguna. En las 90 cámaras externas de la partición general de entrenamiento son vacías el 69.9 %, y en las 30 externas de validación el 47.4 %. Segundo, las cámaras externas contienen las especies que en CCT-20 son raras: el ciervo pasa de 44 cajas en el `train` de A a 3 276 en el de B, y el zorro de 5 a 669 (figura 8, apéndice). Tercero, la partición general es coherente con la oficial: las 10 cámaras cis pertenecen a su `train` y las 10 trans a su `val`. Por tanto, añadir las cámaras externas de `train` no contamina ningún conjunto de prueba, y las externas de `val` constituyen un segundo conjunto de cámaras nuevas, el *trans ampliado* (figura 4, apéndice).

Las imágenes externas se descargan del conjunto completo de 105 GB alojado en LILA BC y se reescalan al lado mayor de entrada. Cada imagen recibe un estado: *vacía*, *con caja* o *animal sin caja*. Las últimas se excluyen del entrenamiento y de la evaluación por cajas, porque tratarlas como fondo introduciría falsos negativos en la supervisión, pero permanecen en el flujo del módulo de monitoreo. Las cajas de taxones ajenos a las 15 clases (lagartija, puma, insecto, murciélago) se descartan en entrenamiento y se ignoran en evaluación.

3.2. Arquitectura

Se usa YOLOv8-s (11.1 M de parámetros, 28.7 GFLOPs a 640 px; figura 1). La red troncal CSPDarknet termina en un módulo SPPF (He et al., 2015) y entrega mapas de paso 8, 16 y 32 a un cuello PAN-FPN. El cabezal desacoplado predice en cada celda ($80^2+40^2+20^2 = 8\,400$ candidatos a 640 px) una distribución de 16 valores por lado de la caja y 15 puntuaciones de clase.

La asignación de candidatos a verdades de terreno sigue a Feng et al. (2021): para cada par se calcula

$$t = s^{\alpha}\, u^{\beta}, \qquad \alpha = 0.5,\ \beta = 6, \tag{1}$$

con s la puntuación de la clase verdadera y u el IoU de la caja predicha, y a cada objeto se asignan

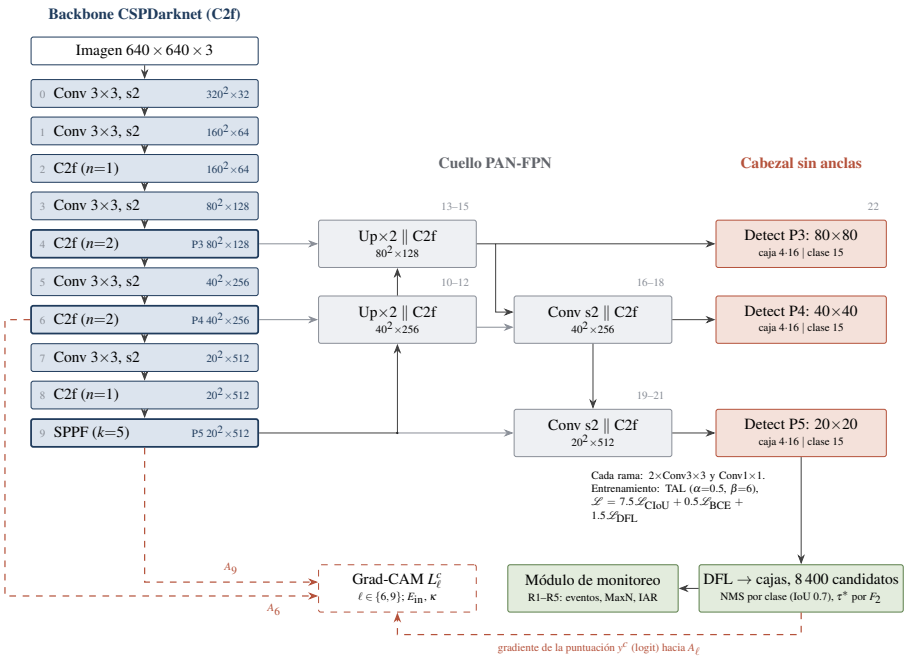


Figura 1: YOLOv8-s ajustado a las 15 clases de CCT-20. Los índices grises numeran las capas; ‖ denota concatenación por canales. Las flechas discontinuas marcan las activaciones A_6 y A_9 y el gradiente de la puntuación de clase usados por Grad-CAM (apartado 3.5).

los $k_{\text{TAL}} = 10$ candidatos de mayor t. La función objetivo es

$$\mathscr{L} = \lambda_{\text{box}}\,\mathscr{L}_{\text{CIoU}} + \lambda_{\text{cls}}\,\mathscr{L}_{\text{BCE}} + \lambda_{\text{dfl}}\,\mathscr{L}_{\text{DFL}}, \qquad (\lambda_{\text{box}}, \lambda_{\text{cls}}, \lambda_{\text{dfl}}) = (7.5,\ 0.5,\ 1.5), \tag{2}$$

con la pérdida de regresión de Zheng et al. (2020),

$$\mathscr{L}_{\text{CIoU}} = 1 - \text{IoU} + \frac{\rho^2(\mathbf{b}, \mathbf{b}^{\text{gt}})}{c^2} + \alpha_v v, \quad v = \frac{4}{\pi^2}\left(\arctan\frac{w^{\text{gt}}}{h^{\text{gt}}} - \arctan\frac{w}{h}\right)^2, \quad \alpha_v = \frac{v}{(1-\text{IoU}) + v}, \tag{3}$$

donde ρ es la distancia entre centros y c la diagonal de la caja envolvente mínima. La pérdida focal distribucional (Li et al., 2020) concentra la masa de cada lado en los enteros $y_i \le y < y_{i+1}$ que rodean al objetivo y:

$$\mathscr{L}_{\text{DFL}}(S_i, S_{i+1}) = -\big[(y_{i+1} - y)\log S_i + (y - y_i)\log S_{i+1}\big]. \tag{4}$$

Un candidato no asignado solo contribuye a $\mathscr{L}_{\text{BCE}}$, con objetivo cero en las 15 clases; esa es la supervisión del fondo, sin una clase *empty*.

3.3. Decisiones de entrenamiento y tratamiento del fondo

La tabla 9 (apéndice) resume las decisiones. Tres responden a propiedades del dominio. Beery et al. (2018) usaron la inversión horizontal como único aumento; aquí se conserva y se excluyen la inversión vertical y la rotación, porque la gravedad fija la orientación de los animales y la cámara no se mueve. Las capturas nocturnas son infrarrojas y monocromas, de modo que la perturbación de tono carece de significado físico y se anula. El mosaico (Bochkovskiy et al., 2020) diversifica el contexto de cada animal, una presión directa contra el atajo de fondo, y se desactiva en las 10 últimas épocas.

El diseño preveía incorporar imágenes vacías como negativos explícitos hasta una fracción $f = 10\,\%$, muestreadas por cámara. La auditoría mostró que el `train` oficial de CCT-20 contiene 12 099 imágenes con caja, 1 454 con animal sin caja y ninguna vacía. A se mantuvo fiel al protocolo oficial, sin importar vacías de otras cámaras. Para que la ablación aislara el efecto de las cámaras y no el del fondo, B usó la misma fracción, $f_A = 0$. En ambos modelos la supervisión del fondo procede, por tanto, de las regiones sin animal de las imágenes con fauna. Su magnitud se acota con la siguiente proposición.

Proposición 1. *Sea una imagen con n objetos y $N = 8\,400$ candidatos. Con la asignación de Feng et al. (2021), que asigna como máximo k_{TAL} candidatos por objeto, la fracción de candidatos supervisados como fondo es al menos $1 - k_{\mathrm{TAL}}\, n/N$.*

Demostración. Cada objeto selecciona a lo sumo k_{TAL} candidatos, y un candidato asignado a varios objetos se conserva para uno solo, luego hay a lo sumo $k_{\mathrm{TAL}}\, n$ positivos. Los $N - k_{\mathrm{TAL}}\, n$ restantes reciben objetivo nulo en $\mathscr{L}_{\mathrm{BCE}}$ (ecuación (2)). □

Con $\bar{n} = 12\,617/12\,099 \approx 1.04$ cajas por imagen en A, la cota da más de un 99.8 % de candidatos de fondo por imagen. Lo que falta no es supervisión negativa sino diversidad de escenas vacías, como viento, vegetación o cambios de luz. Sus consecuencias se miden con la tasa de falsos positivos en vacías (apartado 4.2), y las vacías intervienen explícitamente en la validación (24.8 % de las 4 254 imágenes), en la selección del umbral y en todas las métricas de prueba. B suma 56 cámaras y 24 573 cajas, frente a 10 cámaras y 12 617 cajas de A: solo 46 de las 90 cámaras externas contienen cajas de las 15 clases (tabla 10, apéndice). Ambos se seleccionan con `cis_val∪trans_val` y parada temprana de paciencia 15.

3.4. Protocolo de evaluación

Una detección $\hat{b}$ empareja con una caja verdadera b de la misma clase si $\mathrm{IoU}(\hat{b}, b) = |\hat{b} \cap b| / |\hat{b} \cup b| \geq t$. Siguiendo a Lin et al. (2014), las detecciones se procesan en orden decreciente de puntuación con emparejamiento único. Con la precisión interpolada $\tilde{p}(r) = \max_{r' \geq r} p(r')$,

$$\begin{aligned} \mathrm{AP}_{c,t} &= \frac{1}{101} \sum_{r \in \{0, 0.01, \ldots, 1\}} \tilde{p}(r), \\ \mathrm{mAP@0.5} = \frac{1}{|C|} \sum_{c} \mathrm{AP}_{c,0.5}, &\qquad \mathrm{mAP@0.5{:}0.95} = \frac{1}{10|C|} \sum_{c} \sum_{t \in T} \mathrm{AP}_{c,t}, \end{aligned} \tag{5}$$

con $T = \{0.50, 0.55, \ldots, 0.95\}$. Beery et al. (2018) consideran IoU ≥ 0.5 el criterio adecuado para CCT dada la variabilidad entre anotadores (Everingham et al., 2010); se reportan ambas métricas. Las predicciones usan puntuación mínima 10^{-3}, NMS por clase con IoU 0.7 y 100 detecciones por imagen.

Ponderación de las vacías del trans ampliado. De las cerca de 18 000 vacías de las 30 cámaras externas de validación se descarga una de cada $k = 3$ por cámara, y cada una se pondera por k. Para cualquier estadístico aditivo sobre imágenes $S = \sum_i g(i)$, como los conteos de verdaderos y falsos positivos que forman la curva precisión-recall, el estimador de Horvitz-Thompson

$$\hat{S} = \sum_{i \in \mathscr{M}} \frac{g(i)}{\pi_i}, \qquad \pi_i = \begin{cases} 1/k & \text{si } i \text{ es vacía,} \\ 1 & \text{en otro caso,} \end{cases} \tag{6}$$

es insesgado, $\mathbb{E}[\hat{S}] = S$, porque cada imagen entra en la muestra $\mathscr{M}$ con probabilidad π_i. Tras la ponderación, las vacías representan el 76.4 % de las 11 629 imágenes evaluadas. La cifra supera al 47.4 % del total porque las imágenes con animal sin caja, el 38 % de esas cámaras, no admiten evaluación por cajas.

Brecha e intervalos. La brecha se expresa en puntos y como incremento relativo del error (Beery et al., 2018),

$$\Delta = \mathrm{mAP}_{\mathrm{cis}} - \mathrm{mAP}_{\mathrm{nuevo}}, \qquad \Delta_{\mathrm{rel}} = \frac{1 - \mathrm{mAP}_{\mathrm{nuevo}}}{1 - \mathrm{mAP}_{\mathrm{cis}}} - 1. \tag{7}$$

Los intervalos al 95 % se obtienen con *bootstrap* de percentiles (Efron & Tibshirani, 1993), remuestreando cámaras con reemplazo ($B = 300$), porque las imágenes de una cámara no son independientes. En cada réplica se aplica la misma muestra de cámaras a A y a B, lo que produce un intervalo pareado para la mejora $\mathrm{mAP}_B - \mathrm{mAP}_A$. El evaluador se implementó desde cero para admitir pesos y subgrupos ignorados, y su salida coincide con `pycocotools` hasta la última cifra (tabla 11, apéndice).

Umbral de operación. Cada modelo opera con

$$\tau^* = \arg\max_{\tau} F_2(\tau), \qquad F_\beta = \frac{(1+\beta^2)\,PR}{\beta^2 P + R}, \tag{8}$$

elegido en validación, con $\beta = 2$ para ponderar el recall cuatro veces más que la precisión (van Rijsbergen, 1979). Resulta $\tau_A^* = 0.29$ y $\tau_B^* = 0.19$, frente a 0.49 y 0.42 si se maximizara F_1. La asimetría se fundamenta en la apartado 5.

3.5. Dependencia del fondo: Grad-CAM y contrafactual

Para una caja verdadera b de clase c, se elige entre los 8 400 candidatos el de mayor puntuación de c con IoU ≥ 0.3 respecto de b, y su *logit* y^c se retropropaga hasta la activación $A_\ell \in \mathbb{R}^{K\times H\times W}$ (Selvaraju et al., 2017):

$$\alpha_k^c = \frac{1}{HW}\sum_{i,j}\frac{\partial y^c}{\partial A_{\ell,ij}^k}, \qquad L_\ell^c = \mathrm{ReLU}\Big(\sum_k \alpha_k^c A_\ell^k\Big), \tag{9}$$

con $\ell = 9$ (SPPF, paso 32, la última capa de la red troncal) y $\ell = 6$ (C2f, paso 16) como verificación de resolución. Se definen

$$E_{\text{in}} = \frac{\sum_{p\in b} L_\ell^c(p)}{\sum_{p\in I} L_\ell^c(p)}, \qquad \kappa = \frac{E_{\text{in}}}{|b|/|I|}. \tag{10}$$

Proposición 2. *Sea μ_S la media de L_ℓ^c sobre la región S. Entonces $\kappa = \mu_b/\mu_I$; además $\kappa > 1$ si y solo si $\mu_b > \mu_{I\setminus b}$, y $\kappa \leq |I|/|b|$.*

Demostración. De la ecuación (10), $E_{\text{in}} = |b|\mu_b/(|I|\mu_I)$, luego $\kappa = \mu_b/\mu_I$. Como $\mu_I = \frac{|b|}{|I|}\mu_b + \frac{|I\setminus b|}{|I|}\mu_{I\setminus b}$ es una combinación convexa con pesos positivos, $\mu_b > \mu_I \iff \mu_b > \mu_{I\setminus b}$. La cota se sigue de $E_{\text{in}} \leq 1$. □

Por la proposición 2, $\kappa \leq 1$ indica que la evidencia de la clase no está más concentrada en el animal que en el resto de la escena. La cota implica que las cajas grandes empujan κ hacia 1 por construcción, de modo que solo se comparan dominios con distribuciones de tamaño parecidas. Las mismas 250 cajas por dominio se analizan con A y con B, y los regímenes se comparan con la prueba de Mann–Whitney (Mann & Whitney, 1947).

Contrafactual de fondo. La mediana píxel a píxel de las vacías de la cámara ℓ en el modo de captura $m \in \{\text{color}, \text{IR}\}$,

$$B_{\ell,m}(p) = \mathrm{med}_{j\in\mathscr{V}_{\ell,m}} I_j(p), \qquad |\mathscr{V}_{\ell,m}| \leq 40, \tag{11}$$

estima su fondo. En imágenes con un único animal, la caja ampliada un 10 % se sustituye por $\gamma \odot B_{\ell,m}$, con γ la razón de medianas por canal fuera de la caja. La *persistencia* es la fracción de casos detectados a τ^* que mantienen una detección de la misma especie (IoU ≥ 0.3, puntuación $\geq \tau^*$) sin el animal. Como tercera prueba se reporta la tasa de falsos positivos en vacías, $\mathrm{FPR}_\varnothing$, y el AUROC de la puntuación máxima por imagen entre vacía y fauna; este último no depende del umbral y permite comparar A con B.

3.6. Oclusión y tamaño

CCT no anota oclusión. La visibilidad v es la fracción de píxeles de la caja que difieren del fondo de la cámara:

$$\begin{aligned} v &= \frac{1}{|b|}\sum_{p\in b} \mathbb{1}\big[D(p) > \theta\big], \qquad D = G_\sigma * \big|I - \gamma B_{\ell,m}\big|, \\ \theta &= \max\big(12,\ \mathrm{med}(D_{\bar{b}}) + 3\cdot 1.4826\,\mathrm{MAD}(D_{\bar{b}})\big), \end{aligned} \tag{12}$$

con $\bar{b}$ el complemento de las cajas. Una caja ocupada por vegetación o roca reproduce el fondo y tiene v bajo. Normalizando con el percentil 75 por especie, $v_{75}(c)$,

$$o = \text{máx}\Big(\underbrace{\text{clip}\left(1 - v/v_{75}(c),\, 0,\, 1\right)}_{o_{\text{vis}}},\ \underbrace{0.5\mathbb{1}[\eta = 1] + 0.8\mathbb{1}[\eta \geq 2]}_{o_{\text{tr}}},\ \underbrace{\max_{b' \neq b} |b \cap b'|/|b|}_{o_{\text{sol}}}\Big), \tag{13}$$

donde η es el número de bordes del encuadre que toca la caja. Los niveles son bajo $[0, 1/3)$, medio $[1/3, 2/3)$ y alto $[2/3, 1]$. Como o_{vis} puede confundir oclusión y camuflaje (Beery et al., 2018), el estimador se contrasta con 120 cajas etiquetadas a ciegas por un modelo multimodal (Anthropic, 2026) y revisadas a mano (apéndice A.1), con el κ_w cuadrático de Cohen (1968). El tamaño se mide a la resolución de entrada con los umbrales de COCO (Lin et al., 2014): pequeño si el área es menor que 32^2 px, mediano si es menor que 96^2 y grande en el resto. En cada subgrupo se ignoran las cajas ajenas. El indicador principal es el recall a τ^*, R@τ^*, que no depende de cómo se atribuyan los falsos positivos a los subgrupos.

3.7. Módulo de monitoreo ecológico

El módulo transforma detecciones por fotograma en un reporte de actividad mediante cinco reglas. **R1**: se conservan las detecciones con puntuación $\geq \tau^*$. **R2**: NMS agnóstico a la especie con IoU 0.6, para no contar un individuo como dos especies. **R3**: un fotograma sin detecciones es vacío; en otro caso registra el número de individuos n_k por especie. **R4**: dos registros de una especie pertenecen a eventos distintos si

$$t_k - t_{k-1} > \Delta_{\text{ind}} = 30 \text{ min}, \tag{14}$$

el criterio de independencia de O'Brien et al. (2003) recomendado por Meek et al. (2014). **R5**: cada evento e se resume con $\text{MaxN}_e = \text{máx}_{k \in e}\, n_k$, y cada especie con el índice de abundancia relativa $\text{IAR} = 100 N_{\text{ev}}/D$, con D los días de operación. El reporte se agrega por madrugada [0, 6) h, mañana [6, 12) h, tarde [12, 18) h y noche [18, 24) h. Se demuestra sobre el flujo completo de la cámara del trans ampliado de mayor riqueza etiquetada: la cámara 60, con 405 fotogramas en 177 días, que ningún modelo vio. El mismo módulo aplicado a las etiquetas verdaderas produce la referencia.

3.8. Extensión entre conjuntos de datos

Se evaluaron A y B sin reentrenar sobre ENA24-detection (Yousif et al., 2019): 8 789 imágenes del este de Norteamérica con 9 772 cajas, de un bosque templado caducifolio y con otro hardware de captura. A diferencia de conjuntos neotropicales como Orinoquía (Vélez et al., 2023), tiene cajas en todas sus imágenes, lo que permite el mismo mAP, y comparte 13 de las 15 clases. Cada taxón s se asigna a la clase más específica que lo contiene,

$$m(s) = \operatorname*{arg\,max}_{c \in C:\ s \preceq c} \text{prof}(c), \tag{15}$$

con $s \preceq c$ la pertenencia al clado de c. Así, *Tamias* y *Marmota* (Sciuridae) van a `squirrel`. En la ejecución reportada, la implementación por subcadenas asignó *Sciurus niger* (*eastern fox squirrel*) a `fox`; el cuaderno corrige el orden de las reglas, y el efecto se limita a las clases `fox` y `squirrel` de ENA24. Los taxones sin clase contenedora (10.5 % de las cajas) no son verdad de terreno de ninguna clase, pero las detecciones sobre ellos cuentan como falsos positivos. Además se reporta un AP agnóstico a la especie, $\text{AP}^{\text{agn}}_{50}$, que aísla la localización.

4. Resultados

4.1. Desempeño global y por especie

La parada temprana detuvo A en la época 37 y B en la 45, y B alcanzó pérdidas de validación menores en los tres términos (figura 6, apéndice). La tabla 1 resume los cuatro dominios. En cis, A alcanza un mAP@0.5 de 66.6 % (IC 95 % [60.4, 74.2]) y B de 73.5 % ([64.9, 85.3]), una mejora pareada de 6.9 puntos ([1.2, 17.6]). Ambas cifras quedan por debajo del 77 % de Faster R-CNN (Beery et al., 2018), entrenado a mayor resolución (lado mayor de 1024 px) y con dos etapas.

Tabla 1: Desempeño por dominio y modelo. AP_{50}^{agn}: AP agnóstico a la especie. Las columnas centrales descomponen las cajas verdaderas al umbral τ^* de cada modelo. $FPR_{\varnothing}$: fracción de vacías con alguna detección $\geq \tau^*$ (ENA24 no tiene vacías).

		Detección			Cajas reales a τ^* (%)			
Dominio	Mod.	mAP_{50}	$mAP_{50:95}$	AP_{50}^{agn}	Correcta	Confundida	Omitida	$FPR_{\varnothing}$
cis	A	66.6	44.0	92.8	83.8	7.0	9.3	14.0
	B	73.5	50.8	93.7	88.4	5.5	6.1	30.5
trans	A	40.6	27.8	85.3	69.1	15.6	15.3	36.7
	B	48.5	31.1	89.1	76.4	12.6	11.1	30.8
trans ampliado	A	21.0	13.1	20.8	14.0	37.7	48.2	34.9
	B	51.7	43.0	58.0	61.4	9.6	29.0	21.8
ENA24	A	18.2	12.0	69.3	28.4	39.1	32.5	–
	B	33.2	23.0	83.0	49.2	30.6	20.2	–

La tabla 2 desagrega el AP@0.5 por especie. En A, el desbalance determina el desempeño: la correlación de Spearman (Spearman, 1904) entre $AP_{c,0.5}$ y $\log_{10} n_{\text{train},c}$ es $\rho = 0.63$ ($p = 0.011$) en cis y 0.56 ($p = 0.036$) en trans. Las especies con menos de 50 cajas (ciervo, tejón, zorro) obtienen entre 0 y 33 % en cis, y en trans el AP medio es 52.8 % en las especies por encima de la mediana de cajas frente a 24.4 % en las de debajo. B multiplica por 74 las cajas de ciervo y por 134 las de zorro, y la correlación deja de ser significativa: $\rho = 0.19$ ($p = 0.491$), 0.36 ($p = 0.202$) y -0.04 en el trans ampliado. La diferencia entre especies frecuentes y raras en trans se reduce de 28.4 a 19.1 puntos (58.0 % frente a 38.9 %). Los mayores avances se concentran en las especies que más datos ganaron, como ciervo (cis: de 32.8 a 65.5 %), roedor y zorro en el trans ampliado (figura 2). En cambio, aves y roedores siguen por debajo del 10 % en trans, y la ardilla no se detecta en el trans ampliado con ninguno de los modelos. Son especies pequeñas y miméticas, cuya escasa señal visual no compensa el volumen de datos.

Tabla 2: AP@0.5 por especie (%) para A y B en cada dominio, con el número de cajas de entrenamiento n_{train} de cada modelo. "–": especie ausente del dominio.

	n_{train}		cis		trans		trans ampliado		ENA24	
Especie	A	B	A	B	A	B	A	B	A	B
opossum	2 514	2 869	87.2	91.3	85.3	85.0	53.6	62.2	37.3	31.2
rabbit	2 278	3 477	85.6	89.0	44.3	58.8	16.4	57.0	45.9	41.6
coyote	1 371	2 887	90.7	93.1	47.7	76.4	18.4	66.1	21.3	45.1
cat	1 170	1 322	85.2	87.4	23.6	34.7	57.7	100.0	6.0	7.9
squirrel	1 037	1 212	63.6	70.9	30.9	33.0	0.3	0.5	10.4	12.3
raccoon	1 030	2 005	81.2	92.8	67.7	78.5	7.4	19.1	16.4	32.1
dog	769	1 069	69.5	70.5	69.9	72.1	–	–	27.7	39.0
bobcat	684	1 365	82.2	80.0	53.0	64.1	36.5	70.4	14.1	39.9
car	668	670	98.6	98.6	98.5	99.2	–	–	3.8	4.6
bird	560	1 951	58.0	49.6	5.2	8.4	9.5	17.6	32.6	66.4
rodent	264	1 235	78.0	81.4	0.0	2.0	8.7	62.5	–	–
skunk	214	554	87.0	95.2	42.6	66.3	60.5	87.3	21.6	34.0
deer	44	3 276	32.8	65.5	–	–	4.4	56.1	0.1	52.4
badger	9	12	0.0	25.7	0.0	0.0	0.0	8.4	–	–
fox	5	669	0.0	11.1	0.0	0.0	0.0	65.1	0.0	24.4
mAP	12 617	24 573	66.6	73.5	40.6	48.5	21.0	51.7	18.2	33.2

4.2. Generalización entre cámaras

La tabla 3 reporta la brecha de cada modelo. En A, frente a las 9 cámaras trans, $\Delta = 26.0$ puntos (IC 95 % [16.4, 39.9]) y $\Delta_{\text{rel}} = 78$ %, casi el triple del 28 % de Faster R-CNN (Beery et al., 2018). Frente al trans ampliado, la brecha llega a 45.6 puntos ([34.5, 55.8]). Al añadir cámaras, B mejora en trans 7.8 puntos ([5.2, 12.2]), pero como también mejora en cis su brecha queda en 25.0 puntos ([13.7, 40.3]). En el trans ampliado, en cambio, la mejora es de 30.7 puntos ([23.1, 43.7]) y la brecha se reduce a 21.8 puntos, porque esas cámaras se parecen más a las externas incorporadas en B que a las

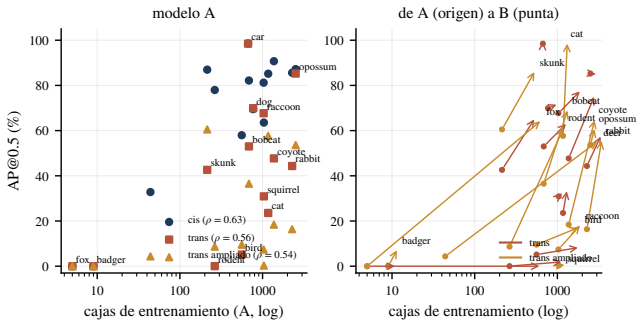


Figura 2: Izquierda: AP@0.5 por especie del modelo A frente a sus cajas de entrenamiento. Derecha: desplazamiento de cada especie de A (origen) a B (punta) en los dos dominios de cámaras nuevas.

Tabla 3: Brecha entre cámaras vistas y nuevas (ecuación (7)), con IC por *bootstrap* de cámaras.

Modelo	Dominio nuevo	mAP_{50} cis	mAP_{50} nuevo	Δ	IC 95 %	Δ_{rel} (%)
A	trans	66.6	40.6	26.0	[16.4, 39.9]	78
A	trans ampliado	66.6	21.0	45.6	[34.5, 55.8]	137
B	trans	73.5	48.5	25.0	[13.7, 40.3]	94
B	trans ampliado	73.5	51.7	21.8	[7.8, 31.1]	82

Tabla 4: Pruebas de dependencia del fondo. $\tilde{\kappa}_\ell$: concentración mediana de Grad-CAM en la capa ℓ (ecuación (10)); $\tilde{E}_{\text{in}}$: fracción mediana de energía en la caja (capa 9); persistencia: detecciones que sobreviven al reemplazo del animal por el fondo de su cámara.

Modelo	Dominio	$\tilde{\kappa}_9$	$\tilde{\kappa}_6$	$\tilde{E}_{\text{in}}$ (%)	Persistencia (%)	$\text{FPR}_\varnothing$ (%)	AUROC
A	cis	0.60	0.94	1.3	8.4	14.0	0.963
A	trans	0.34	0.90	0.7	9.7	36.7	0.865
A	trans ampliado	0.86	1.06	5.9	4.4	34.9	0.712
B	cis	0.98	0.86	2.3	0.0	30.5	0.917
B	trans	0.82	0.94	1.6	0.0	30.8	0.922
B	trans ampliado	0.93	1.05	5.5	35.0	21.8	0.879

de CCT-20. B también uniformiza el desempeño entre cámaras: el coeficiente de variación del mAP por cámara baja de 0.40 a 0.28 en trans y de 0.59 a 0.26 en el trans ampliado (figura 7, apéndice). Estos resultados confirman la hipótesis de Schneider et al. (2020).

La comparación con el AP agnóstico localiza el fallo. En trans, A localiza el 85.3 % de los animales pero solo alcanza un 40.6 % de mAP por clase. A τ^*, el 15.6 % de las cajas se localiza con la especie equivocada y el 15.3 % se omite. Como observaron Beery et al. (2018), la clasificación es más frágil que la detección frente al cambio de cámara. En el trans ampliado, A pierde además la localización ($\text{AP}_{50}^{\text{agn}} = 20.8\,\%$, 48.2 % de omisiones), y B la recupera hasta 58.0 %.

Evidencia sobre el aprendizaje del fondo. La tabla 4 reúne las tres pruebas. La más concluyente es la separabilidad entre vacías y fauna, independiente del umbral. En A, el AUROC cae de 0.963 en cis a 0.865 en trans y 0.712 en el trans ampliado. Al mismo umbral, la tasa de falsos positivos en vacías pasa de 14.0 % a 36.7 %: el detector responde al fondo de cámaras que no conoce con la misma confianza que a un animal. B mantiene el AUROC en 0.917, 0.922 y 0.879, de modo que la diversidad de cámaras estabiliza el rechazo del fondo.

Grad-CAM apunta en la misma dirección. La concentración mediana en la capa 9 es menor que 1 en todos los casos (figura 5, apéndice), y los mapas de la figura 3 resaltan con frecuencia vegetación, bordes del encuadre y zonas iluminadas antes que al animal. En A, $\tilde{\kappa}$ baja de 0.60 en cis a 0.34 en trans (Mann–Whitney $p = 0.072$). En B, la concentración es mayor en ambos dominios (0.98 y 0.82). El trans ampliado se excluye de esta comparación porque sus cajas grandes acercan κ a 1 (proposición 2). El contrafactual muestra que la detección desaparece casi siempre al retirar al animal en cis y trans (persistencia de 8.4 y 9.7 % en A, nula en B). El detector usa al animal cuando lo detecta, y la dependencia del contexto se manifiesta sobre todo como falsos positivos en escenas vacías desconocidas. La persistencia de B en el trans ampliado (35.0 %) no se interpreta, porque allí

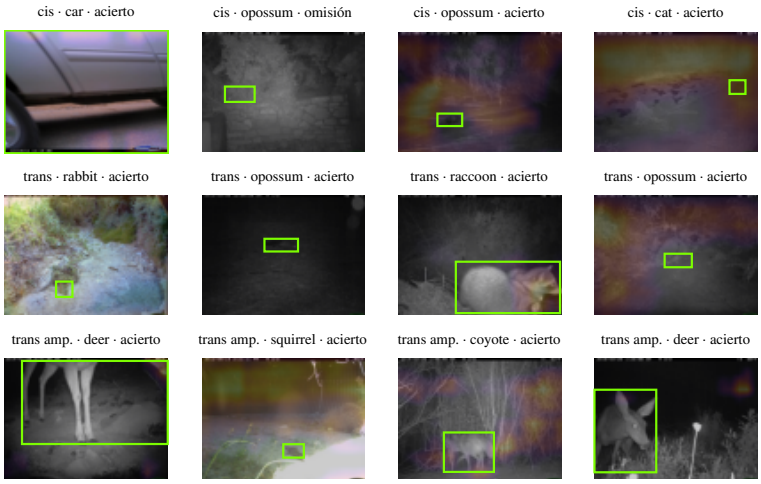


Figura 3: Mapas Grad-CAM de la capa 9 del modelo B en cámaras vistas y nuevas, con la caja verdadera en verde.

predominan cajas que ocupan casi todo el encuadre y dejan sin contexto el cálculo de γ.

4.3. Robustez ante oclusión y tamaño

Tabla 5: Recall a τ^* (%) por nivel estimado de oclusión y por tamaño (umbrales de COCO a 640 px).

	cis			trans			trans ampliado		
Subgrupo	n	R@τ^* A	R@τ^* B	n	R@τ^* A	R@τ^* B	n	R@τ^* A	R@τ^* B
Oclusión bajo	3 783	90.9	92.3	4 094	77.2	82.9	2 479	17.4	65.2
Oclusión medio	2 436	83.2	88.3	4 368	65.9	74.2	1 673	14.7	65.8
Oclusión alto	7 045	80.0	86.3	10 324	67.1	74.6	1 780	8.7	51.9
Tamaño pequeño	170	27.1	33.5	127	8.7	19.7	196	0.5	7.1
Tamaño mediano	7 137	81.3	86.9	10 723	70.6	76.4	1 425	18.6	45.0
Tamaño grande	5 957	88.2	91.8	7 936	67.9	77.1	4 311	13.1	69.2

El tamaño domina sobre la oclusión (tabla 5; figura 9, apéndice). Las cajas pequeñas son raras (1 a 3 % del total), pero su recall a τ^* es de 27.1 % en cis y 8.7 % en trans con A, frente a más del 80 % de las grandes en cis. La caída entre grandes y pequeñas es de 61.1 y 59.2 puntos. B mejora las pequeñas en trans hasta 19.7 % sin cerrar la diferencia. Esto es coherente con la resolución de 640 px, que reduce un animal lejano de una imagen de 1024 px a pocas celdas de paso 8. La oclusión estimada tiene un efecto monótono pero moderado: entre los niveles bajo y alto, el recall de A cae 10.9 puntos en cis y 10.1 en trans, y el de B, 6.0 y 8.2. Sin embargo, el estimador infla el nivel alto, sobre todo en tomas nocturnas de bajo contraste ($\kappa_w = 0.18$, IC 95 % [0.03, 0.33]; apéndice A.1), de modo que esa caída mezcla oclusión y baja visibilidad.

4.4. Módulo de monitoreo

En la cámara 60, la referencia registra 49 eventos independientes de 8 especies. El módulo produce 48 eventos de 9 especies con A y 62 de 12 con B (tablas 6 y 7). El total de A coincide por compensación de errores. Ningún modelo registra los 16 eventos de lagartija, una especie ausente del espacio de etiquetas, y ambos subestiman la ardilla (5 eventos frente a 13). A cambio, A inventa 10 eventos de coyote y 6 de conejo, y B 19 de ciervo y 5 de coyote. Por eso el error agregado por especie es del 61.2 % con A y del 69.4 % con B. La fracción de fotogramas sin fauna sube de 10.9 % en la referencia a 58.5 % y 53.8 % según los módulos. El lince conserva su patrón nocturno, aunque B lo sobreestima (figura 10, apéndice). La especie ajena al espacio de etiquetas desaparece del reporte sin señal de alerta.

Tabla 6: Resumen de la cámara 60.

Indicador	Referencia	Módulo A	Módulo B
Fotogramas analizados	405	405	405
Fotogramas sin fauna (%)	10.9	58.5	53.8
Especies distintas	8	9	12
Eventos independientes	49	48	62
Días de operación	177	177	177

Tabla 7: Eventos por especie y periodo: modelo B (referencia); última columna: eventos de A.

Especie	Madrug.	Mañana	Tarde	Noche	Eventos	MaxN	IAR	Eventos A
bird	0 (0)	3 (0)	0 (1)	0 (0)	3 (1)	1 (1)	1.7 (0.6)	2
bobcat	4 (3)	0 (0)	4 (2)	6 (4)	14 (9)	1 (1)	7.9 (5.1)	9
cat	0 (0)	0 (0)	0 (0)	1 (1)	1 (1)	1 (1)	0.6 (0.6)	3
lizard	0 (0)	0 (4)	0 (12)	0 (0)	0 (16)	0 (1)	0 (9.0)	0
opossum	0 (0)	0 (0)	1 (2)	2 (2)	3 (4)	2 (1)	1.7 (2.3)	3
raccoon	1 (1)	0 (0)	1 (0)	3 (3)	5 (4)	1 (1)	2.8 (2.3)	3
rodent	0 (1)	0 (0)	1 (0)	1 (0)	2 (1)	1 (1)	1.1 (0.6)	0
squirrel	0 (0)	2 (5)	3 (8)	0 (0)	5 (13)	1 (1)	2.8 (7.3)	5
coyote	1 (0)	1 (0)	2 (0)	1 (0)	5 (0)	1 (0)	2.8 (0)	10
deer	3 (0)	5 (0)	9 (0)	2 (0)	19 (0)	2 (0)	10.7 (0)	0
fox	1 (0)	0 (0)	0 (0)	1 (0)	2 (0)	1 (0)	1.1 (0)	0
rabbit	0 (0)	0 (0)	1 (0)	1 (0)	2 (0)	1 (0)	1.1 (0)	6
skunk	0 (0)	0 (0)	1 (0)	0 (0)	1 (0)	1 (0)	0.6 (0)	0

4.5. Generalización a otra región

Sobre ENA24, A alcanza un mAP@0.5 de 18.2 % y B de 33.2 % (IC 95 % por *bootstrap* de imágenes: [17.5, 19.6] y [32.0, 34.7]). El AP agnóstico es mucho mayor, 69.3 % y 83.0 %: ambos detectores encuentran a los animales del otro bioma pero fallan al nombrarlos. A τ^*, A confunde la especie en el 39.1 % de las cajas y B en el 30.6 % (figura 12, apéndice). A, con 44 cajas de entrenamiento, clasifica como coyote el 49 % de los ciervos de cola blanca (AP de 0.1 %). B, que vio ciervos de las cámaras externas, alcanza un AP de 52.4 % aunque la especie oriental es otra.

5. Discusión

Uso responsable de la IA en conservación. Los dos tipos de error no tienen el mismo costo. Un falso positivo consume minutos de revisión de un especialista. Un falso negativo de una especie amenazada la retira del registro: su ocupación y su abundancia relativa se subestiman, y las decisiones de manejo se toman sin ella. Como la revisión humana corrige los falsos positivos pero nadie revisa lo que el sistema descartó, la asimetría justifica operar a alto recall. De ahí la elección de τ^* por F_2 (ecuación (8)), que en validación da un recall de 79.0 % con una precisión de 71.5 % en B, y la recomendación de enviar a revisión toda detección entre τ^* y τ_{F_1}, además de toda secuencia con una especie de interés.

El segundo riesgo es desplegar el detector en otra región sin validación local: ni 46 cámaras adicionales cerraron la brecha frente a las trans. En la Amazonía y los Andes peruanos, la fauna objetivo (tapir, pecarí, jaguar, oso de anteojos) no pertenece al espacio de etiquetas, y el caso de la lagartija muestra que el detector la omitirá o la asignará a la clase visualmente más cercana sin señal de incertidumbre. El sotobosque denso agrava además la oclusión y reduce el tamaño aparente. Un despliegue responsable exige validación etiquetada en las cámaras de destino, recalibrar τ^* y abstenerse ante especies fuera del espacio de etiquetas. La brecha entre $\mathrm{AP}_{50}^{\mathrm{agn}}$ y mAP en ENA24 (cerca de 50 puntos en B) respalda la alternativa de dos etapas: un detector agnóstico seguido de un clasificador regional (Beery et al., 2019; Shepley et al., 2021).

Limitaciones. (1) El `train` oficial no contiene vacías y B replicó esa fracción, de modo que ningún modelo vio escenas vacías. (2) B difiere de A en número de cámaras y en composición de especies; la mitad de las cajas del trans ampliado es de ciervo, y la ablación no separa ambos efectos. (3) El estimador de oclusión sobrestima el nivel en tomas de bajo contraste (apéndice A.1). (4) Grad-CAM tiene resolución gruesa en la capa 9, y tanto κ como el contrafactual dependen del tamaño de la caja. (5) Se usó una semilla, 640 px y evaluación por fotograma. (6) ENA24 carece de ubicaciones y de vacías, y el mapeo asignó *Sciurus niger* a `fox`.

6. Conclusiones

Con el protocolo oficial, YOLOv8-s alcanza 66.6 % de mAP@0.5 en cámaras vistas y 40.6 % en nuevas; la caída se concentra en la clasificación y en el rechazo del fondo. Añadir cámaras externas mejora todos los dominios y atenúa el efecto del desbalance, sin cerrar la brecha frente a las cámaras trans. El tamaño del objeto domina la dificultad, y un monitoreo con totales correctos puede ocultar errores de composición.

Referencias

Anthropic. (2026). Claude. https://www.anthropic.com/claude

Beery, S., Morris, D., & Yang, S. (2019). Efficient pipeline for camera trap image review.

Beery, S., Van Horn, G., & Perona, P. (2018). Recognition in Terra Incognita. *Computer Vision – ECCV 2018*, *11220*, 456-473. https://doi.org/10.1007/978-3-030-01270-0_28

Bochkovskiy, A., Wang, C.-Y., & Liao, H.-Y. M. (2020). YOLOv4: Optimal speed and accuracy of object detection.

Cohen, J. (1968). Weighted kappa: Nominal scale agreement provision for scaled disagreement or partial credit. *Psychological Bulletin*, *70*(4), 213-220. https://doi.org/10.1037/h0026256

Efron, B., & Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall.

Everingham, M., Van Gool, L., Williams, C. K. I., Winn, J., & Zisserman, A. (2010). The PASCAL visual object classes (VOC) challenge. *International Journal of Computer Vision*, *88*(2), 303-338. https://doi.org/10.1007/s11263-009-0275-4

Feng, C., Zhong, Y., Gao, Y., Scott, M. R., & Huang, W. (2021). TOOD: Task-aligned one-stage object detection. *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*, 3490-3499. https://doi.org/10.1109/ICCV48922.2021.00349

Geirhos, R., Jacobsen, J.-H., Michaelis, C., Zemel, R., Brendel, W., Bethge, M., & Wichmann, F. A. (2020). Shortcut learning in deep neural networks. *Nature Machine Intelligence*, *2*(11), 665-673. https://doi.org/10.1038/s42256-020-00257-z

He, K., Zhang, X., Ren, S., & Sun, J. (2015). Spatial pyramid pooling in deep convolutional networks for visual recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, *37*(9), 1904-1916. https://doi.org/10.1109/TPAMI.2015.2389824

Jocher, G., Chaurasia, A., & Qiu, J. (2023). *Ultralytics YOLOv8* (Ver. 8.0.0). https://github.com/ultralytics/ultralytics

Koh, P. W., Sagawa, S., Marklund, H., Xie, S. M., Zhang, M., Balsubramani, A., Hu, W., Yasunaga, M., Phillips, R. L., Gao, I., Lee, T., David, E., Stavness, I., Guo, W., Earnshaw, B., Haque, I., Beery, S. M., Leskovec, J., Kundaje, A., … Liang, P. (2021). WILDS: A benchmark of in-the-wild distribution shifts. *Proceedings of the 38th International Conference on Machine Learning*, *139*, 5637-5664.

Landis, J. R., & Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics*, *33*(1), 159-174. https://doi.org/10.2307/2529310

Li, X., Wang, W., Wu, L., Chen, S., Hu, X., Li, J., Tang, J., & Yang, J. (2020). Generalized focal loss: Learning qualified and distributed bounding boxes for dense object detection. *Advances in Neural Information Processing Systems*, *33*, 21002-21012.

Lin, T.-Y., Dollár, P., Girshick, R., He, K., Hariharan, B., & Belongie, S. (2017). Feature pyramid networks for object detection. *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2117-2125. https://doi.org/10.1109/CVPR.2017.106

Lin, T.-Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., & Zitnick, C. L. (2014). Microsoft COCO: Common objects in context. *Computer Vision – ECCV 2014*, *8693*, 740-755. https://doi.org/10.1007/978-3-319-10602-1_48

Liu, S., Qi, L., Qin, H., Shi, J., & Jia, J. (2018). Path aggregation network for instance segmentation. *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 8759-8768. https://doi.org/10.1109/CVPR.2018.00913

Mann, H. B., & Whitney, D. R. (1947). On a test of whether one of two random variables is stochastically larger than the other. *The Annals of Mathematical Statistics*, *18*(1), 50-60. https://doi.org/10.1214/aoms/1177730491

Meek, P. D., Ballard, G., Claridge, A., Kays, R., Moseby, K., O'Brien, T., O'Connell, A., Sanderson, J., Swann, D. E., Tobler, M., & Townsend, S. (2014). Recommended guiding principles for reporting on camera trapping research. *Biodiversity and Conservation*, *23*(9), 2321-2343. https://doi.org/10.1007/s10531-014-0712-8

Norouzzadeh, M. S., Nguyen, A., Kosmala, M., Swanson, A., Palmer, M. S., Packer, C., & Clune, J. (2018). Automatically identifying, counting, and describing wild animals in camera-trap images with deep learning. *Proceedings of the National Academy of Sciences*, *115*(25), E5716-E5725. https://doi.org/10.1073/pnas.1719367115

O'Brien, T. G., Kinnaird, M. F., & Wibisono, H. T. (2003). Crouching tigers, hidden prey: Sumatran tiger and prey populations in a tropical forest landscape. *Animal Conservation*, *6*(2), 131-139. https://doi.org/10.1017/S1367943003003172

Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). You only look once: Unified, real-time object detection. *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 779-788. https://doi.org/10.1109/CVPR.2016.91

Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why should I trust you?": Explaining the predictions of any classifier. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 1135-1144. https://doi.org/10.1145/2939672.2939778

Schneider, S., Greenberg, S., Taylor, G. W., & Kremer, S. C. (2020). Three critical factors affecting automated image species recognition performance for camera traps. *Ecology and Evolution*, *10*(7), 3503-3517. https://doi.org/10.1002/ece3.6147

Schneider, S., Taylor, G. W., & Kremer, S. (2018). Deep learning object detection methods for ecological camera trap data. *2018 15th Conference on Computer and Robot Vision (CRV)*, 321-328. https://doi.org/10.1109/CRV.2018.00052

Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. *2017 IEEE International Conference on Computer Vision (ICCV)*, 618-626. https://doi.org/10.1109/ICCV.2017.74

Shepley, A., Falzon, G., Meek, P., & Kwan, P. (2021). Automated location invariant animal detection in camera trap images using publicly available data sources. *Ecology and Evolution*, *11*(9), 4494-4506. https://doi.org/10.1002/ece3.7344

Spearman, C. (1904). The proof and measurement of association between two things. *The American Journal of Psychology*, *15*(1), 72-101. https://doi.org/10.2307/1412159

Tabak, M. A., Norouzzadeh, M. S., Wolfson, D. W., Sweeney, S. J., VerCauteren, K. C., Snow, N. P., Halseth, J. M., Di Salvo, P. A., Lewis, J. S., White, M. D., Teton, B., Beasley, J. C., Schlichting, P. E., Boughton, R. K., Wight, B., Newkirk, E. S., Ivan, J. S., Odell, E. A., Brook, R. K., … Miller, R. S. (2019). Machine learning to classify animal species in camera trap images: Applications in ecology. *Methods in Ecology and Evolution*, *10*(4), 585-590. https://doi.org/10.1111/2041-210X.13120

Terven, J., Córdova-Esparza, D.-M., & Romero-González, J.-A. (2023). A comprehensive review of YOLO architectures in computer vision: From YOLOv1 to YOLOv8 and YOLO-NAS. *Machine Learning and Knowledge Extraction*, *5*(4), 1680-1716. https://doi.org/10.3390/make5040083

Tuia, D., Kellenberger, B., Beery, S., Costelloe, B. R., Zuffi, S., Risse, B., Mathis, A., Mathis, M. W., van Langevelde, F., Burghardt, T., Kays, R., Klinck, H., Wikelski, M., Couzin, I. D., van Horn, G., Crofoot, M. C., Stewart, C. V., & Berger-Wolf, T. (2022). Perspectives in machine learning for wildlife conservation. *Nature Communications*, *13*, 792. https://doi.org/10.1038/s41467-022-27980-y

van Rijsbergen, C. J. (1979). *Information Retrieval* (2.ª ed.). Butterworths.

Vélez, J., McShea, W., Shamon, H., Castiblanco-Camacho, P. J., Tabak, M. A., Chalmers, C., Fergus, P., & Fieberg, J. (2023). An evaluation of platforms for processing camera-trap data using artificial intelligence. *Methods in Ecology and Evolution*, *14*(2), 459-477.

Wang, C.-Y., Liao, H.-Y. M., Wu, Y.-H., Chen, P.-Y., Hsieh, J.-W., & Yeh, I.-H. (2020). CSPNet: A new backbone that can enhance learning capability of CNN. *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, 390-391. https://doi.org/10.1109/CVPRW50498.2020.00203

Wang, C.-Y., Yeh, I.-H., & Liao, H.-Y. M. (2024). YOLOv9: Learning what you want to learn using programmable gradient information.

Yousif, H., Kays, R., & He, Z. (2019). Dynamic programming selection of object proposals for sequence-level animal species classification in the wild. *IEEE Transactions on Circuits and Systems for Video Technology*.

Zheng, Z., Wang, P., Liu, W., Li, J., Ye, R., & Ren, D. (2020). Distance-IoU loss: Faster and better learning for bounding box regression. *Proceedings of the AAAI Conference on Artificial Intelligence*, *34*(07), 12993-13000. https://doi.org/10.1609/aaai.v34i07.6999

A. Material complementario

A.1. Validación del estimador de oclusión

La muestra de validación contiene 120 cajas de `cis_test`, `trans_test` y el trans ampliado, 40 por nivel estimado. La anotación siguió dos etapas. Primero, el anotador multimodal etiquetó cada recorte sin acceso al nivel estimado, según la fracción visible del cuerpo: bajo si se observa más de dos tercios del animal, medio entre uno y dos tercios, y alto por debajo de un tercio. La vegetación, las rocas, otros individuos y el borde del encuadre cuentan como oclusión; el camuflaje y la oscuridad, no. Después, los autores revisaron manualmente las 120 etiquetas con el mismo criterio y las ratificaron sin cambios. Frente a esa referencia, el acuerdo es leve en la escala de Landis y Koch (1977): $\kappa_w = 0.18$, con IC 95 % [0.03, 0.33] por *bootstrap* de cajas, coincidencia exacta del 42.5 % y discrepancia de a lo sumo un nivel en el 80.8 %. La correlación de rangos es positiva pero débil ($\rho = 0.21$, $p = 0.019$).

El error es asimétrico (tabla 12). El estimador asigna un nivel superior al anotado en el 44.2 % de las cajas y uno inferior en el 13.3 %, y la mitad de las cajas que clasifica como de oclusión alta muestran al animal casi completo. Esas cajas tienen un contraste interno, medido como la desviación típica de la intensidad del recorte, con mediana 14.0, frente a 40.8 en el resto del nivel alto (Mann–Whitney $p = 5 \times 10^{-4}$). En el tercil de menor contraste la sobrestimación alcanza el 62.5 % de las cajas, frente al 22.5 % del tercil central. El término o_{vis} de la ecuación (13) interpreta como oclusión la escasa diferencia con el fondo propia de las tomas infrarrojas nocturnas, en las que el animal es visible pero apenas se separa del fondo. Una versión corregida del estimador debería normalizar D por el contraste local o sustituir o_{vis} por una segmentación del animal.

La referencia tiene límites que deben declararse. Los recortes se juzgaron a unos 60 px de lado y sin la imagen completa, solo con la indicación de contacto con el borde del encuadre. La revisión manual partió de las etiquetas propuestas, lo que puede introducir un sesgo de anclaje hacia ellas. Las 12 primeras cajas no se anotaron a ciegas; excluirlas apenas modifica el resultado ($\kappa_w = 0.20$). Por último, el 12.1 % de las cajas carece de modelo de fondo, y su nivel depende solo de o_{tr} y o_{sol}.

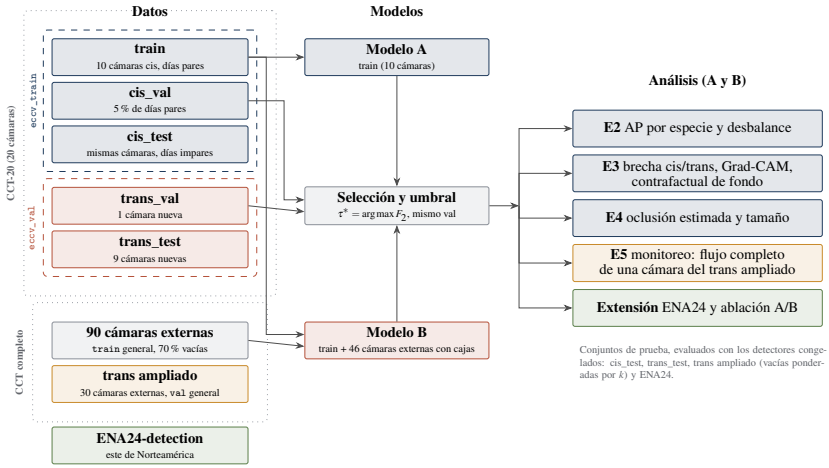


Figura 4: Diseño experimental. A y B comparten validación, umbral de operación y conjuntos de prueba; solo difieren en las cámaras externas de entrenamiento.

Tabla 8: Auditoría del conjunto completo de CCT por grupo de cámaras. "Fuera de clases": cajas de taxones ajenos a las 15 clases de CCT-20.

Grupo	Ubic.	Imágenes	% vacías	Con caja	Cajas	Fuera de clases
CCT-20	20	57 864	6.9	46 026	48 103	0
Externas, `train` general	90	148 435	69.9	11 305	12 062	106
Externas, `val` general	30	38 197	47.4	5 588	6 055	123

Tabla 9: Hiperparámetros comunes a A y B (Ultralytics 8.3.253).

Decisión	Valor	Justificación
Inicialización	pesos COCO	Incluye perros, gatos, aves y vehículos (Lin et al., 2014).
Resolución	640 px	Resolución de preentrenamiento; efecto en objetos pequeños en la apartado 4.3.
Épocas	50, paciencia 15	A: 37 (mejor 22); B: 45 (mejor 27).
Optimizador	SGD, $\eta_0 = 0.01$, momento 0.937, $\lambda = 5 \cdot 10^{-4}$, lote 16	Ajuste fino estándar de YOLOv8.
Color	$h = 0$, $s = v = 0.4$	Sin tono en imágenes infrarrojas.
Geometría	inversión horiz. 0.5; escala 0.5; traslación 0.1	Cámara fija y orientación gravitatoria.
Mosaico	1.0; off en las 10 últimas	Contra el atajo de fondo.
MixUp, copy-paste	0	Escenas implausibles.

Tabla 10: Conjuntos de entrenamiento.

Modelo	Cámaras	Imágenes	% fondo	Cajas
A	10	12 099	0.0	12 617
B	56	23 315	0.0	24 573

Tabla 11: Verificación del evaluador propio frente a `pycocotools` y al `val()` de Ultralytics. Las diferencias con Ultralytics (entre 1.8 y 3.2 puntos) se deben a su interpolación y emparejamiento, distintos del protocolo COCO.

	mAP@0.5 (%)			mAP@0.5:0.95 (%)		
Modelo y dominio	propio	pycoco	Ultralytics	propio	pycoco	Ultralytics
A, cis	66.6	66.6	69.4	44.0	44.0	46.2
A, trans	40.6	40.6	43.8	27.8	27.8	30.0
B, cis	73.5	73.5	76.3	50.8	50.8	53.3
B, trans	48.5	48.5	51.0	31.1	31.1	32.9

Tabla 12: Validación del estimador de oclusión: nivel estimado (ecuación (13)) frente al nivel anotado en una muestra estratificada de 120 cajas. La diagonal, en negrita, corresponde a las coincidencias; las celdas sobre ella, a la subestimación, y las celdas bajo ella, a la sobrestimación.

	Nivel anotado			
Nivel estimado	bajo	medio	alto	Total
bajo	**30**	7	3	40
medio	21	**13**	6	40
alto	20	12	**8**	40
Total	71	32	17	120

A.2. Reproducibilidad

Todo el estudio se ejecuta con el cuaderno `P3_CamarasTrampa_YOLOv8.ipynb` (Colab, GPU T4, Ultralytics 8.3.253). Las descargas del conjunto completo, los entrenamientos y las inferencias se reanudan desde Google Drive. Las semillas, las listas de imágenes y el orden de las clases se fijan en la primera ejecución.

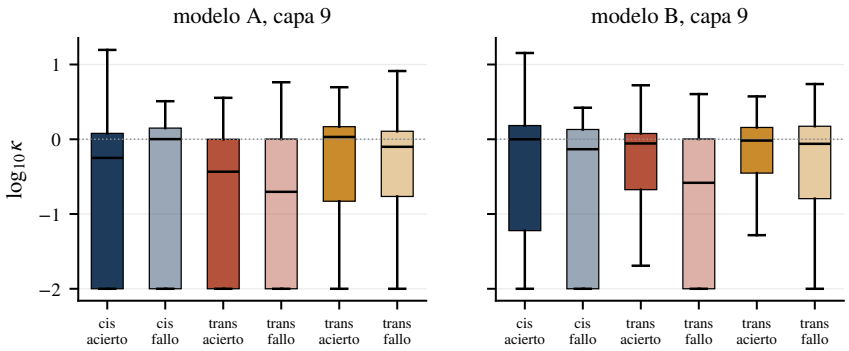


Figura 5: $\log_{10}\kappa$ por dominio y resultado de la detección; la línea punteada marca la atención uniforme, $\kappa = 1$.

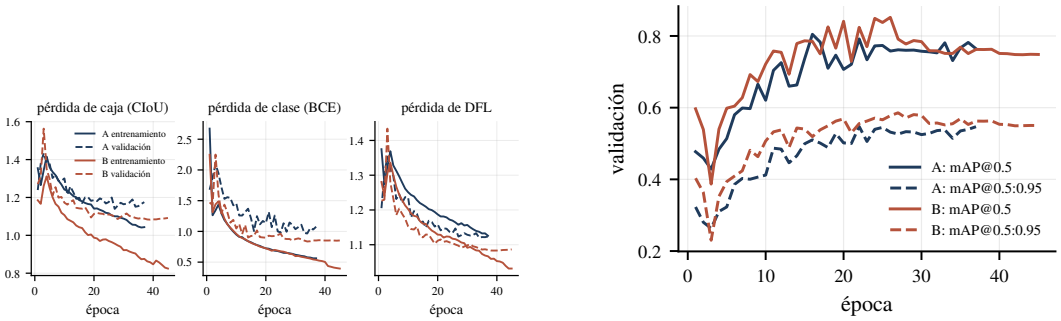


Figura 6: Pérdidas de entrenamiento y validación (izquierda) y mAP de validación por época (derecha) de A y B.

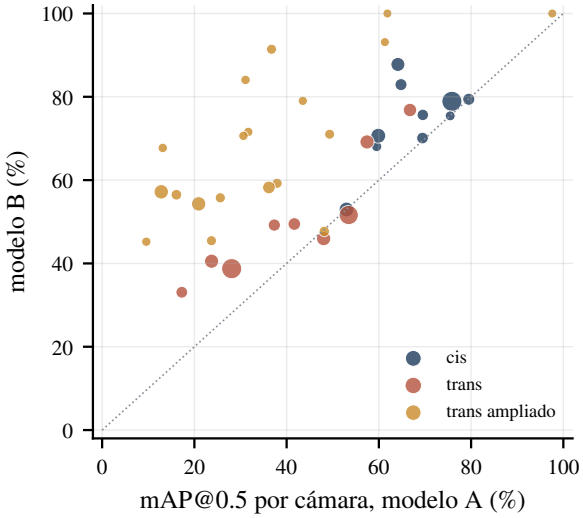


Figura 7: mAP@0.5 por cámara, A frente a B. El tamaño del punto es proporcional al número de imágenes; los puntos sobre la diagonal indican mejora de B.

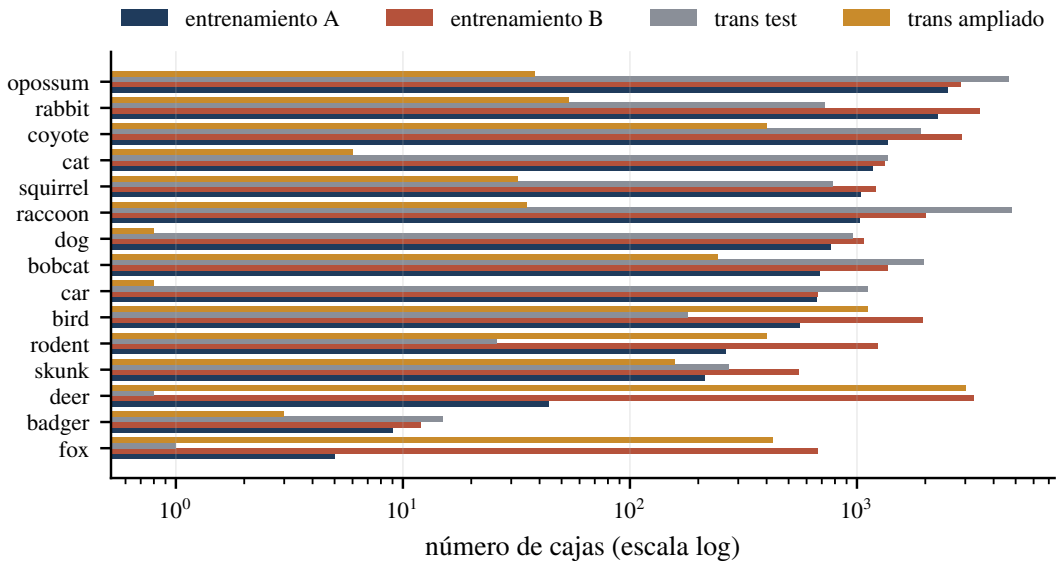


Figura 8: Cajas por especie en los conjuntos de entrenamiento de A y B y en los dos conjuntos de cámaras nuevas.

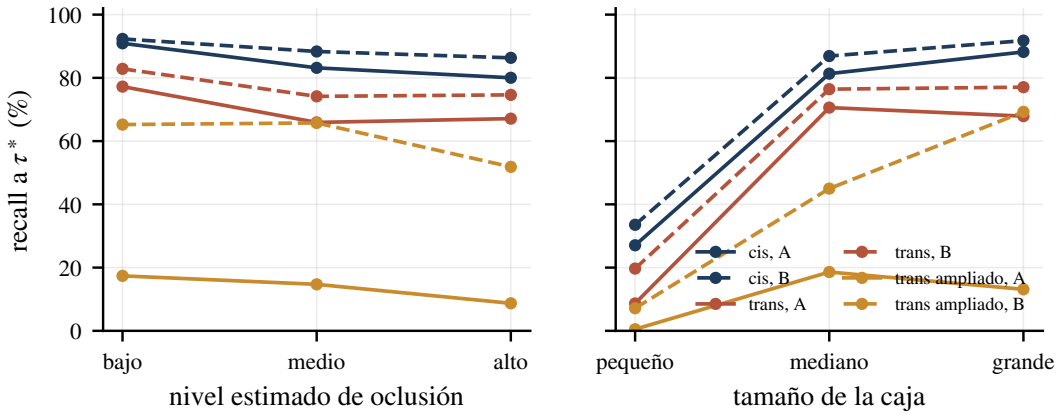


Figura 9: Recall a τ^* por nivel de oclusión y por tamaño (línea continua: A; discontinua: B).

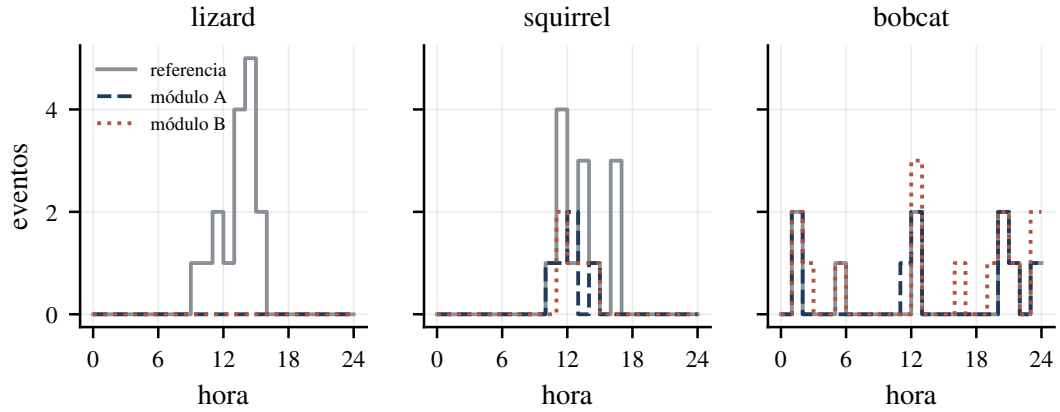


Figura 10: Eventos independientes por hora en la cámara 60: referencia, módulo con A y módulo con B.

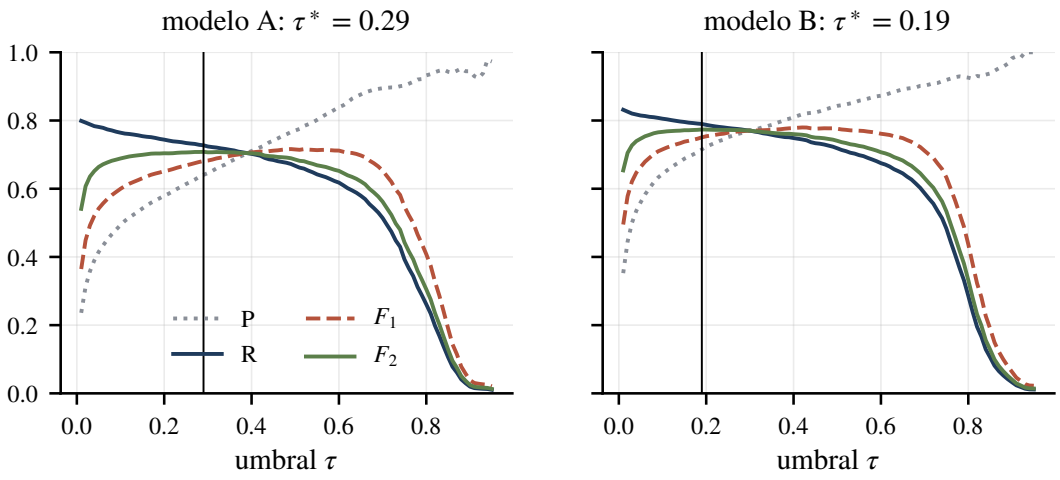


Figura 11: Precisión, recall, F_1 y F_2 en validación según el umbral, para A y B.

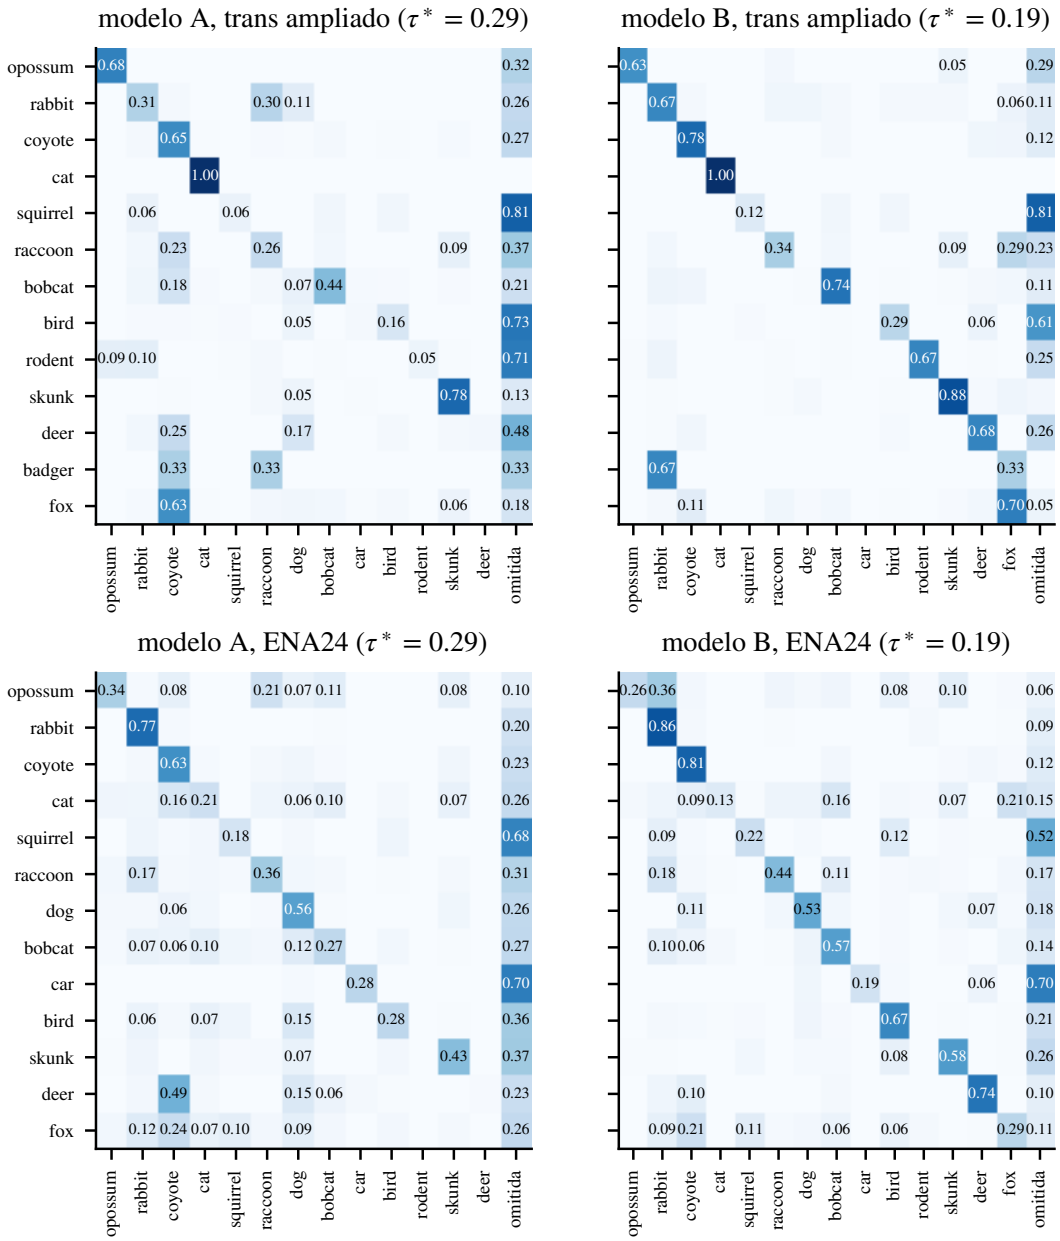


Figura 12: Matrices de confusión a τ^*, normalizadas por fila, en el trans ampliado (arriba) y en ENA24 (abajo). La última columna recoge las cajas omitidas.